

Санкт-Петербургский государственный университет

Информационно-аналитические системы

Группа 22.М04-мм

Екатерина Петровна Винник

Прогнозирование отказов жестких дисков системы Tatlin.Unified

Отчёт по учебной практике

Научный руководитель:
к.ф.-м.н., доц. Е.Г. Михайлова

Консультант:
В.И. Гориховский

Санкт-Петербург
2022

Saint Petersburg State University

Software and Administration of Information Systems

Group 22.M04-mm

Ekaterina Vinnik

Failure Prediction in Tatlin.Unified Hard Disk Drives

Internship report

Scientific supervisor:
C.Sc, docent. E.G. Mikhailova

Consultant:
V. I. Gorikhovskii

Saint Petersburg
2022

Оглавление

Введение	4
Постановка задачи	6
1. Существующие подходы к прогнозированию отказа жесткого диска	7
1.1. Использование байесовского классификатора	7
1.2. Использование метода опорных векторов	7
1.3. Использование скрытой марковской модели	8
1.4. Использование расстояния Махаланобиса	8
1.5. Использование автокодировщиков	9
1.6. Метод K ближайших соседей	9
1.7. Метод случайного леса	10
2. Применение подходов на наборе модельных данных	11
2.1. Выбор набора модельных данных	11
2.2. Гипотеза о важности S.M.A.R.T. параметров при классификации отказа диска	12
2.3. Применение метода опорных векторов	13
2.4. Применение метода K ближайших соседей	13
2.5. Применение метода случайного леса	14
Заключение	15
Список литературы	16

Введение

Жесткие диски являются одним из самых распространенных устройств хранения и присутствуют в разных системах — от персональных компьютеров до систем хранения данных. Согласно [7], большинство информации, производимой в мире, хранится на жестких дисках. Частота отказов жесткого диска в год составляет чуть меньше 1% [17], что не удовлетворяет большое количество пользователей, так как в некоторых высоко масштабируемых системах, например, в центрах обработки данных или поставщиках интернет-услуг количество жестких дисков в одном вычислительном узле может легко достигать тысячи [1]. Отказ каждого из этих жестких дисков может не только увеличить время простоя сервиса, но и привести к потере данных. Задача предсказания отказа жесткого диска является актуальной и для жестких дисков систем хранения данных компании YADRO, которая, согласно данным отчета корпорации IDC (INTERNATIONAL DATA CORPORATION), является лидером российского рынка внешних систем хранения данных в емкостном выражении с долей 63.7%¹. На данный момент компания YADRO разрабатывает семейство систем хранения данных TATLIN — TATLIN.ARCHIVE, TATLIN.UNIFIED, TATLIN.OBJECT. Так как для систем хранения данных семейства TATLIN прогнозирование отказов жестких дисков не производится, поддержка прогнозирования позволила бы повысить надежность хранения данных в этих системах.

Существующая широко применяемая технология прогнозирования отказа жесткого диска S.M.A.R.T. (*self-monitoring, analysis and reporting technology*) заключается в отслеживании значений набора параметров на предмет превышения соответствующих пороговых значений. Хотя эта технология широко используется, частота предсказания отказов диска с ее помощью является достаточно низкой — ввиду стремления ее создателями снизить количество ложных положительных классификаций, технология S.M.A.R.T. позволяет предсказать от 3% до 10% отказов [10][11][8].

¹<https://st.yadro.com/docs/idc-whitepaper-rus.pdf> Дата последнего обращения 27.12.2022

Для повышения частоты предсказания отказа дисков разрабатывались разные подходы, использующие в своей основе данные о поведении диска, собираемые с помощью технологии S.M.A.R.T.. Большинство этих подходов заключается в применении методов машинного обучения к данным, собираемым технологией S.M.A.R.T. [5][10][12][19][20]. Это связано с тем, что задача прогнозирования отказа диска является задачей бинарной классификации, которая в свою очередь является одной из самых распространенных задач, решаемых с помощью алгоритмов машинного обучения.

Ввиду того, что было разработано большое количество подходов для прогнозирования отказов жестких дисков, для поддержки прогнозирования отказов дисков системы хранения данных TALIN.UNIFIED целесообразно сначала произвести анализ разработанных подходов. Применение набора подходов для прогнозирования отказа жестких дисков системы хранения данных TALIN.UNIFIED с последующим сравнением результатов, полученных с помощью этих подходов, позволит выбрать наилучший подход для прогнозирования отказа жестких дисков и интегрировать его, повысив тем самым надежность хранения данных системы.

Постановка задачи

Целью данной работы является поддержать прогнозирование отказов жестких дисков в системе хранения данных TATLIN.UNIFIED.

Для достижения этой цели были поставлены следующие задачи.

- Произвести обзор предметной области;
- Выбрать набор модельных данных и исследовать его, сформулировав ряд закономерностей, характеризующих данные;
- Применить существующие подходы на наборе модельных данных;
- Использовать рассмотренные подходы на реальных данных жестких дисков системы TATLIN.UNIFIED;
- Произвести сравнение примененных к прогнозированию отказов жестких дисков системы TATLIN.UNIFIED подходов;
- Интегрировать наилучший подход к прогнозированию отказов жестких дисков в систему TATLIN.UNIFIED.

1. Существующие подходы к прогнозированию отказа жесткого диска

1.1. Использование байесовского классификатора

Применение наивного байесовского классификатора [5] являлось одной из первых попыток применения методов машинного обучения к прогнозированию отказов жестких дисков. В данном исследовании было сделано предположение о том, что отказ жесткого диска невозможно спрогнозировать менее, чем за 48 часов до его отказа. На основе этого предположения класс отказавших жестких дисков был сформирован из записей, относящихся к последним 48 часам наблюдений за параметрами жесткого диска. Применение этого метода дало достаточно низкую точность классификации — 0.33 % верных положительных классификаций при 0.001% ложных положительных классификаций. Более поздние исследования применимости этого подхода к прогнозированию отказов жестких дисков дали сходные результаты [6].

Также для прогнозирования отказа жесткого диска использовался древовидный алгоритм Байеса [18], который показал 80% верных положительных классификаций при 3% ложных положительных классификаций. Однако при попытке снизить количество ложных положительных классификаций до 0% частота верных положительных классификаций алгоритма снизилась до 20-30%.

1.2. Использование метода опорных векторов

Метод опорных векторов, предложенный в [20], заключается в проецировании исходного набора векторов данных в пространство более высокой размерности и последующем поиске оптимальной разделяющей гиперплоскости [20]. Этот метод также одним из первых стал применяться для прогнозирования отказов дисков [10][11] и позволил классифицировать 50.6% отказов жестких дисков при 0% ложных положительных классификаций. Однако метод требует больших вычислитель-

ных ресурсов, и поэтому распространения в предсказывании отказов жестких дисков в режиме реального времени не получил.

1.3. Использование скрытой марковской модели

Хотя скрытые марковские модели, предложенные Баумом в 1966 [2], исторически широко применялись для задач распознавания речи, алгоритмы машинного обучения на основе марковских моделей были применены и для прогнозирования отказа жесткого диска [14]. В исследовании [14] авторы рассмотрели последовательности значений параметров жесткого диска, измеренных в последовательные промежутки времени и применили скрытые марковские модели для моделирования этих последовательностей. Подход с использованием скрытой марковской модели позволил достичь 52% положительных классификаций при 0% ложных положительных классификаций, что сравнимо с результатом, полученным с помощью метода опорных векторов.

1.4. Использование расстояния Махаланобиса

Подход, использующий расстояние Махаланобиса [12] [21] для прогнозирования отказов жестких дисков, основан на вычислении расстояния Махаланобиса — обобщенном расстоянии, позволяющем измерить сходство между новым наблюдением и набором уже известных наблюдений с помощью рассмотрения корреляций между наблюдениями. Вычисленные значения расстояния Махаланобиса используются четырьмя оценщиками для вычисления значений, сравниваемых с пороговыми. Диск считается отказавшим, если результирующее значение какого-либо из оценщиков превысило пороговое значение.

Данный подход показал результаты, превосходящие метод опорных векторов — 67% положительных классификаций при 0% ложных положительных классификаций. Также подход, использующий расстояние Махаланобиса значительно опередил метод опорных векторов в вычислительной скорости, показав 4.3 минуты против 17983 минут, достигнутых методом опорных векторов. Этот показатель очень важен, так как

низкая производительность метода опорных векторов являлась сдерживающим фактором в его использовании для прогнозирования отказов дисков на системах в режиме реального времени. Подход, использующий расстояние Махаланобиса, также позволил предсказать 56% отказов жестких дисков за 20 часов до отказа.

1.5. Использование автокодировщиков

Автокодировщики достаточно часто используются для выявления аномалий [9][22][16], и в частности они применяются и для выявления отказов жестких дисков [19]. В исследовании [19] рассмотрено несколько подходов к использованию автокодировщиков для выявления отказов жестких дисков.

Первый из подходов, описанных в [19] использует для классификации наличия отказа диска размер ошибки восстановления — если ошибка восстановления превышает пороговое значение, считается, что произошел отказ жесткого диска. Второй из подходов, описанных в [19] заключается в проверке сходства очередного объекта тренировочной выборки с остальными объектами в пространстве меньшей размерности с использованием расстояния Махаланобиса для измерения сходства. В случае, если расстояние Махаланобиса для очередного объекта превысило пороговое значение, считается, что произошел отказ жесткого диска. Третий подход, описанный в [19], является комбинацией метрик предыдущих двух подходов. Третий подход показал наибольшую частоту положительных классификаций по сравнению с первыми двумя — 28.09% при 10% ложных положительных классификаций. Результатов применения подходов при 0% ложных положительных классификаций представлено не было.

1.6. Метод K ближайших соседей

Метод K ближайших соседей, представленный в [4] — это метрический алгоритм классификации, основанный на вычислении оценок

сходства между объектами. Для предсказания целевого признака для нового объекта x производятся следующие шаги:

- Вычисляются расстояния от x до всех объектов обучающей выборки;
- Объекты обучающей выборки сортируются по возрастанию расстояний до x ;
- Выбираются k объектов с наименьшими расстояниями до x ;
- По этим k объектам вычисляется ответ на задачу предсказания.

Данный метод, примененный для решения задачи классификации отказа жесткого диска [13], позволил идентифицировать наибольшее по сравнению с остальными методами количество отказов жестких дисков — 0.97% при 0.003% ложных положительных классификаций.

1.7. Метод случайного леса

Метод случайного леса, заключающийся в использовании набора решающих деревьев для решения задачи классификации, был представлен в [3] и сочетает в себе применение метода бэггинга для построения ансамбля деревьев и метода случайных подпространств.

Примененный для прогнозирования отказов жестких дисков, он показал худшие результаты по сравнению с методом K ближайших соседей, позволив идентифицировать 0.943% отказов дисков при 0.004% ложных положительных классификаций. Тем не менее этот результат является вторым по количеству идентифицированных отказавших дисков среди рассмотренных подходов при одном из самых низких процентов ложных положительных классификаций.

2. Применение подходов на наборе модельных данных

2.1. Выбор набора модельных данных

В большинстве исследований, приведенных в главе 1, применимость разработанных подходов к прогнозированию отказов жестких дисков оценивалась на каком-либо из следующих наборов данных [15]:

- *University of California dataset*²
- *Baidu dataset*
- *Quantum Corporation dataset*
- *Backblaze dataset*³

Набор данных, предоставленный университетом Калифорнии использовался, например, в работах [10][11]. Недостатком этого набора данных является то, что его признаки не являются непосредственно S.M.A.R.T. параметрами, что снижает применимость выводов, сделанных на основе этого набора данных, к реальным данным, составленным из значений S.M.A.R.T.. Кроме того, набор данных университета Калифорнии был собран достаточно давно и поэтому гипотезы, сделанные на основе этих данных, могут быть не применимы к данным, собранным в настоящее время.

Набор данных корпорации *Quantum* использовался, например, в работе [5]. Так как этот набор данных имеет 11 признаков, соответствующих S.M.A.R.T. параметрам и был собран достаточно давно, гипотезы, опробованные на этом наборе данных, могут быть не применимы к реальным данным жестких дисков, имеющих более 200 S.M.A.R.T. параметров.

²<https://web.archive.org/web/20100611213812/http://cmrr.ucsd.edu/> Дата последнего обращения 27.12.2022

³<https://www.backblaze.com/b2/hard-drive-test-data.html> Дата последнего обращения 27.12.2022

Из двух аналогичных наборов данных, предоставленных центрами обработки данных *Baidu* и *Backblaze*, был выбран предобработанный набор данных⁴ на основе данных центра *Backblaze*. Этот набор данных содержит данные одной модели жесткого диска SEAGATE ST4000DM000 и содержит данные о 120 днях работы до отказа для отказавших дисков и 120 произвольных днях работы для дисков, работающих корректно.

Этот набор данных содержал дублирующие друг друга признаки, а также признаки, имеющие константные значения на всем наборе данных, что позволило в результате предобработки сократить количество признаков с 90 до 17.

2.2. Гипотеза о важности S.M.A.R.T. параметров при классификации отказа диска

Следующие S.M.A.R.T. параметры считаются критически важными для прогнозирования отказа дисков⁵:

- Количество перераспределенных секторов (*Reallocated sectors count*)
- Сквозная ошибка (*End-to-end error*)
- Сообщения о неисправимых ошибках (*Reported Uncorrectable Errors*)
- Текущее количество ожидающих секторов (*Current Pending Sector Count*)
- Количество неисправимых секторов (*Uncorrectable Sector Count*)

Исходя из того, что эти параметры считаются критическими, использование только их для обучения может улучшить характеристики модели. Справедливость данного предположения проверялась с помощью нескольких методов: метода опорных векторов, метода K ближайших соседей, метода случайного леса. Результаты работы методов измерялись с помощью метрик FAR — частоты ложных положительных

⁴<https://www.kaggle.com/datasets/awant08/hard-drive-failure-prediction-st4000dm000> Дата последнего обращения 27.12.2022

⁵https://en.wikipedia.org/wiki/Self-Monitoring,_Analysis_and_Reporting_Technology#cite_note-1-25 Дата последнего обращения 27.12.2022

классификаций и FDR (*False Discovery Rate*) — отношения выявленных отказавших дисков к общему числу отказавших дисков.

2.3. Применение метода опорных векторов

Так как рассмотренный в разделе 1.2 метод опорных векторов одним из первых применялся к прогнозированию отказа жестких дисков, было принято решение оценить применимость этого метода к прогнозированию отказов жестких дисков модели SEAGATE ST4000DM000. Данный метод подтвердил свою низкую производительность в прогнозировании отказа жестких дисков и на 17 выделенных признаках за время, значительно превосходящее время обучения других моделей, не удалось обучить модель с использованием метода опорных векторов.

В результате применения данного метода к данным модели SEAGATE ST4000DM000 на 5 признаках, соответствующих критическим параметрам S.M.A.R.T., были достигнуты следующие метрики:

- $FDR = 1 - \frac{2812}{(2812 + 395)} = 0.123$
- $FAR = \frac{67}{95020} = 0.0007$

2.4. Применение метода K ближайших соседей

Метод K ближайших соседей был выбран ввиду того, что показал наибольшую точность 0.974% при 0.003% ложных положительных классификаций [15][13], а также не требовал предварительной подготовки для его использования, облегчая процесс проверки гипотезы.

В результате применения данного метода к данным модели SEAGATE ST4000DM000 на 17 выделенных признаках были достигнуты следующие метрики:

- $FDR = 1 - \frac{740}{(740 + 2467)} = 0.769$
- $FAR = \frac{411}{95020} = 0.004$

В результате применения данного метода к данным модели SEAGATE ST4000DM000 на 5 признаках, соответствующих критическим S.M.A.R.T., были достигнуты следующие метрики:

- $FDR = 1 - \frac{2817}{(2817 + 390)} = 0.122$
- $FAR = \frac{64}{95020} = 0.0006$

2.5. Применение метода случайного леса

Метод случайного леса был выбран потому, что показал один из лучших результатов [15][13], классифицировав 0.943% отказов жестких дисков при 0.004 ложных положительных классификаций,

В результате применения данного метода к данным модели SEAGATE ST4000DM000 на 17 выделенных признаках были достигнуты следующие метрики:

- $FDR = 1 - \frac{586}{(586 + 2621)} = 1 - 0.183 = 0.817$
- $FAR = \frac{212}{95020} = 0.002$

В результате применения данного метода к данным модели SEAGATE ST4000DM000 на 5 признаках, соответствующих критическим S.M.A.R.T., были достигнуты следующие метрики:

- $FDR = 1 - \frac{2808}{(2808 + 399)} = 0.124$
- $FAR = \frac{67}{95020} = 0.0007$

Использование при обучении только признаков, соответствующих S.M.A.R.T. параметрам, считающимся критическими, значительно увеличило количество ложных отрицательных классификаций, таким образом ухудшив характеристики модели. Таким образом, предположение о том, что использование только признаков, соответствующих критическим S.M.A.R.T. параметрам, улучшит показатели моделей, было опровергнуто, и в дальнейшем при обучении предполагается использовать остальные S.M.A.R.T. параметры.

Заключение

В ходе учебной практики были достигнуты следующие задачи:

- Проведен обзор предметной области и рассмотрены следующие методы машинного обучения для прогнозирования отказа жесткого диска:
 - Использование метода опорных векторов;
 - Использование метода случайного леса;
 - Использование метода K ближайших соседей.
- Сформулирована гипотеза о влиянии критических S.M.A.R.T. параметров на качество обучения модели;
- Сформулированная гипотеза проверена и опровергнута на трех методах, рассмотренных в обзорной части работы:
 - методе опорных векторов;
 - методе случайного леса;
 - методе K ближайших соседей.

В рамках продолжения исследований планируется выполнить следующие задачи:

- Оценить применимость остальных рассмотренных подходов на модельных данных;
- Использовать рассмотренные подходы на реальных данных жестких дисков системы TATLIN.UNIFIED.
- Произвести сравнение примененных к прогнозированию отказов жестких дисков системы TATLIN.UNIFIED подходов.

Список литературы

- [1] Jiang Weihang, Hu Chongfeng, Zhou Yuanyuan, and Kanevsky Arkady. Are Disks the Dominant Contributor for Storage Failures? A Comprehensive Study of Storage Subsystem Failure Characteristics // [ACM Trans. Storage](#). — 2008. — nov. — Vol. 4, no. 3. — Access mode: <https://doi.org/10.1145/1416944.1416946>.
- [2] Baum Leonard E. and Petrie Ted. Statistical Inference for Probabilistic Functions of Finite State Markov Chains // [Annals of Mathematical Statistics](#). — 1966. — Vol. 37. — P. 1554–1563.
- [3] Breiman L. Random Forests // [Machine Learning](#). — 2001. — 10. — Vol. 45. — P. 5–32.
- [4] Fix Evelyn and Hodges Joseph L. Discriminatory Analysis - Nonparametric Discrimination: Consistency Properties // [International Statistical Review](#). — 1989. — Vol. 57. — P. 238.
- [5] Hamerly Greg and Elkan Charles. Bayesian Approaches to Failure Prediction for Disk Drives // [Proceedings of the Eighteenth International Conference on Machine Learning](#). — San Francisco, CA, USA : Morgan Kaufmann Publishers Inc. — 2001. — ICML '01. — P. 202–209.
- [6] Tomer Vikas, Sharma Vedna, Gupta Sonali, and Singh Devesh. Hard disk drive failure prediction using SMART attribute // [Materials Today: Proceedings](#). — 2021. — 04. — Vol. 46.
- [7] Hilbert Martin and López Priscila. The World's Technological Capacity to Store, Communicate, and Compute Information // [Science \(New York, N.Y.\)](#). — 2011. — 02. — Vol. 332. — P. 60–5.
- [8] Hughes Gordon, Murray Joseph, Kreutz-Delgado Ken, and Elkan Charles. Improved disk-drive failure warnings // [Reliability, IEEE Transactions on](#). — 2002. — 10. — Vol. 51. — P. 350 – 357.

- [9] Morales-Forero A. and Bassetto S. [Case Study: A Semi-Supervised Methodology for Anomaly Detection and Diagnosis](#) // 2019 IEEE International Conference on Industrial Engineering and Engineering Management (IEEM). — 2019. — P. 1031–1037.
- [10] Murray Joseph, Hughes Gordon, and Kreutz-Delgado Ken. Hard drive failure prediction using non-parametric statistical methods. — 2003. — 01.
- [11] Murray Joseph F., Hughes Gordon F., and Kreutz-Delgado Kenneth. Machine Learning Methods for Predicting Failures in Hard Drives: A Multiple-Instance Application // J. Mach. Learn. Res. — 2005. — dec. — Vol. 6. — P. 783–816.
- [12] Wang Yu, Miao Qiang, Ma Eden W. M., Tsui Kwok-Leung, and Pecht Michael G. Online Anomaly Detection for Hard Disk Drives Based on Mahalanobis Distance // [IEEE Transactions on Reliability](#). — 2013. — Vol. 62, no. 1. — P. 136–145.
- [13] Pitakrat Teerat, van Hoorn André, and Grunske Lars. [A comparison of machine learning algorithms for proactive hard disk drive failure detection](#). — 2013. — 06. — P. 1–10.
- [14] Zhao Ying, Liu Xiang, Gan Siqing, and Zheng Weimin. [Predicting disk failures with HMM- and HSMM-based approaches](#). — 2010. — 07. — Vol. 6171. — P. 390–404.
- [15] Garcia Marco, Ivanov Vladimir, Kozar Anastasia, Litvinov Stanislav, Reznik Alexey, Romanov Vitaly, and Succi Giancarlo. Review of techniques for predicting hard drive failure with SMART attributes // [International Journal of Machine Intelligence and Sensory Signal Processing](#). — 2018. — 01. — Vol. 2. — P. 151.
- [16] Sakurada Mayu and Yairi Takehisa. [Anomaly Detection Using Autoencoders with Nonlinear Dimensionality Reduction](#) // Proceedings

- of the MLSDA 2014 2nd Workshop on Machine Learning for Sensory Data Analysis. — New York, NY, USA : Association for Computing Machinery. — 2014. — MLSDA'14. — P. 4–11. — Access mode: <https://doi.org/10.1145/2689746.2689747>.
- [17] Schroeder Bianca and Gibson Garth A. Disk Failures in the Real World: What Does an MTTF of 1,000,000 Hours Mean to You? // Proceedings of the 5th USENIX Conference on File and Storage Technologies. — USA : USENIX Association. — 2007. — FAST '07. — P. 1–es.
 - [18] Tan Yongmin and Gu Xiaohui. [On Predictability of System Anomalies in Real World](#) // 2010 IEEE International Symposium on Modeling, Analysis and Simulation of Computer and Telecommunication Systems. — 2010. — P. 133–140.
 - [19] Pereira Francisco Lucas F., Castro Chaves Iago, Gomes João Paulo P., and Machado Javam C. [Using Autoencoders for Anomaly Detection in Hard Disk Drives](#) // 2020 International Joint Conference on Neural Networks (IJCNN). — 2020. — P. 1–7.
 - [20] Vapnik Vladimir. [The Nature of Statistical Learning Theory](#). — 2000. — 01. — P. 69–91. — ISBN: [978-1-4419-3160-3](#).
 - [21] Wang Yu, Miao Qiang, and Pecht Michael. [Health monitoring of hard disk drive based on Mahalanobis distance](#) // 2011 Prognostics and System Health Managment Confernece. — 2011. — P. 1–8.
 - [22] Zhou Chong and Paffenroth Randy C. [Anomaly Detection with Robust Deep Autoencoders](#) // Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. — New York, NY, USA : Association for Computing Machinery. — 2017. — KDD '17. — P. 665–674. — Access mode: <https://doi.org/10.1145/3097983.3098052>.